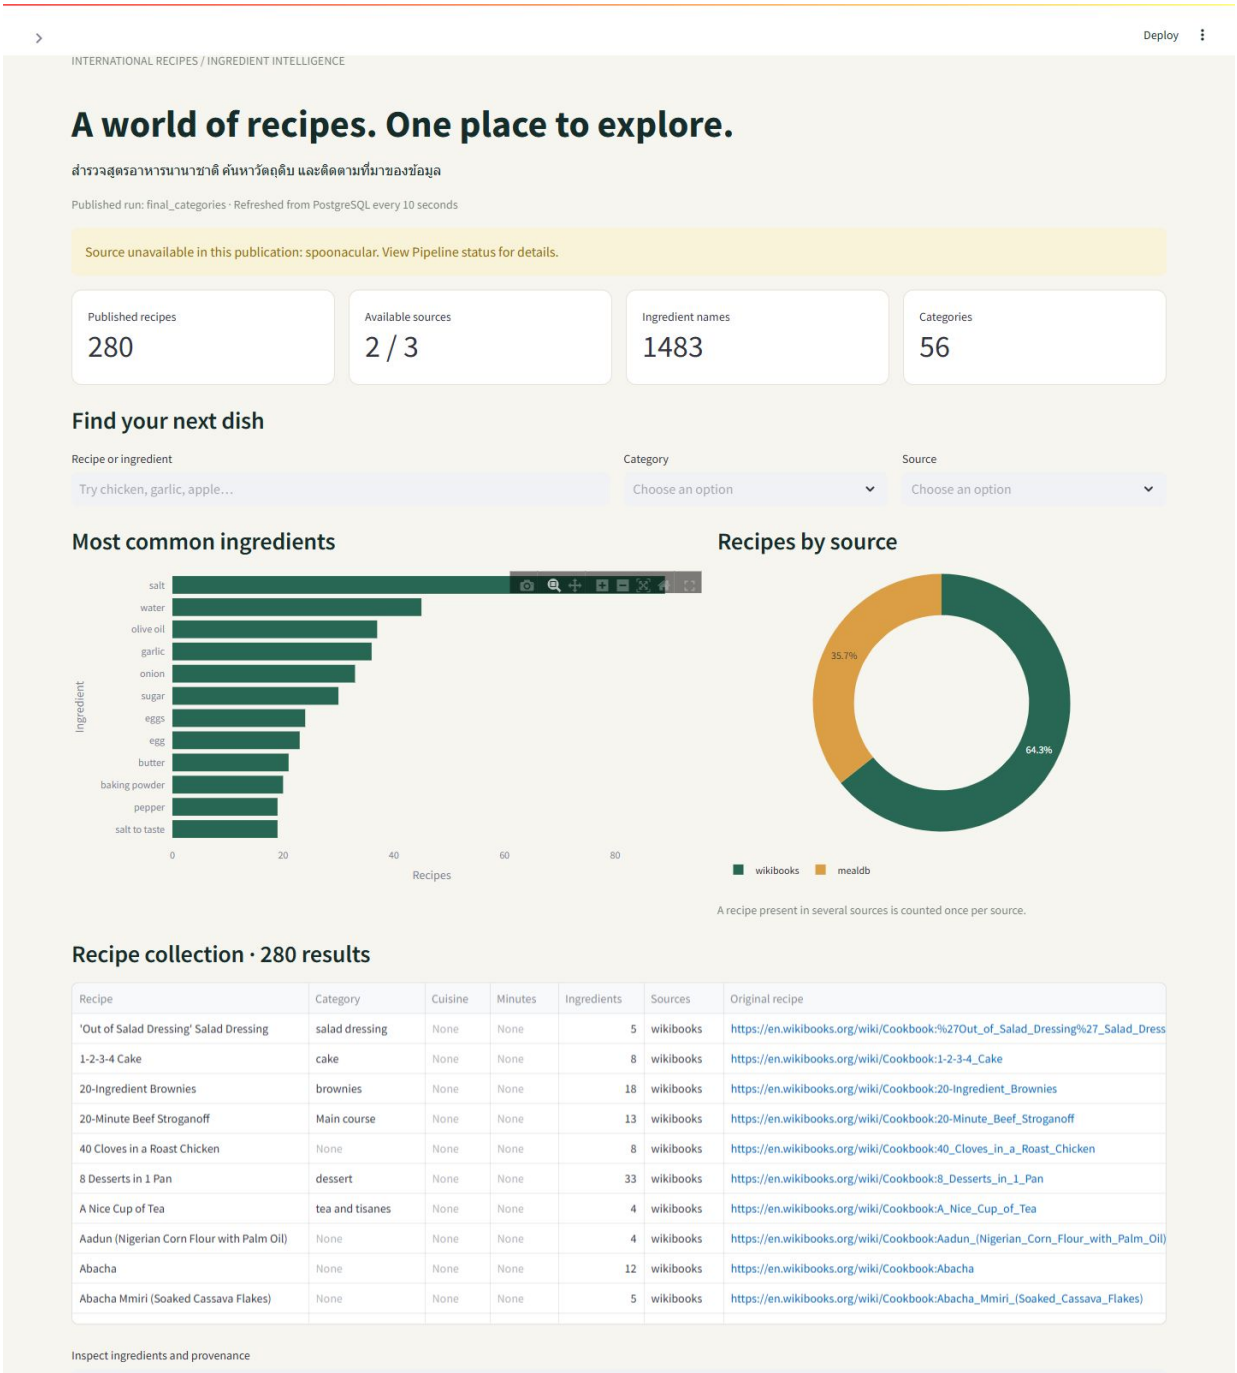
ระบบรวบรวมสูตรอาหารนานาชาติ

และวิเคราะห์วัตถุดิบที่ใช้

โชติณัช โสภาแปง · รหัสนิสิต 6621600828 · ลำดับที่ 5 · วิชา 02739452

GitHub: github.com/Chotinat01/02739452-5-6621600828

ผลที่ตรวจได้จริง: ระดับ 2 และมีหน้าสถานะ pipeline สำหรับโบนัส ดึงข้อมูลจริงผ่าน Airflow และ PostgreSQL รวม 280 สูตร จาก TheMealDB 100 สูตร และ Wikibooks 180 สูตร ส่วน Spoonacular ยังไม่มี API key จึงยังไม่ยืนยันระดับ 3 ครบ

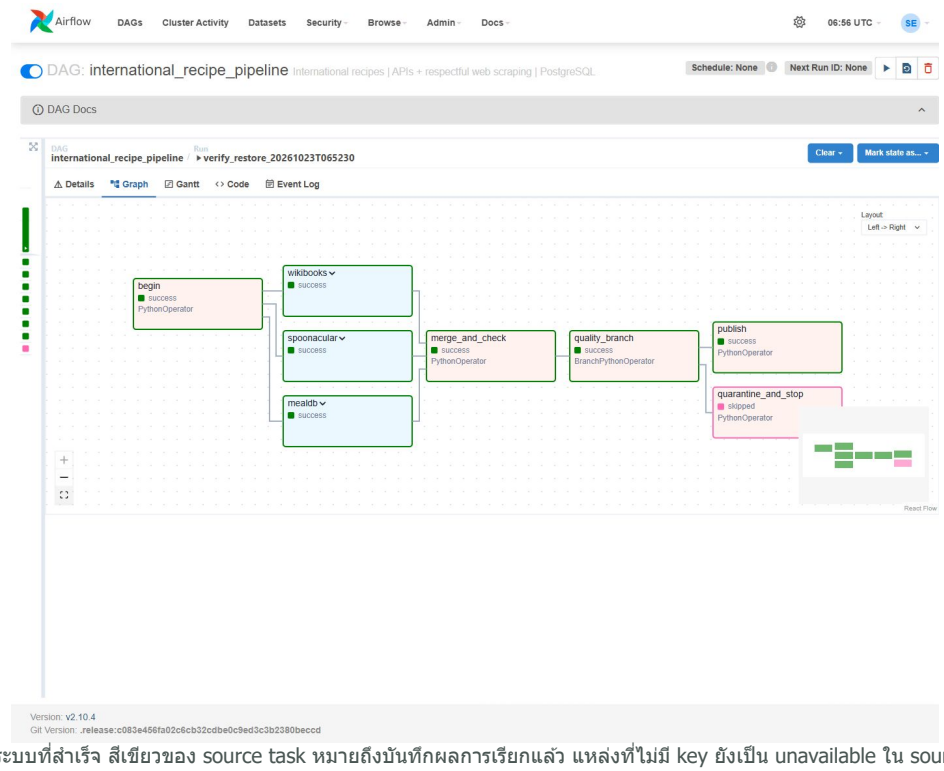


ภาพ dashboard จากระบบจริง แสดง KPI กราฟวัตถุดิบ สัดส่วนแหล่งข้อมูล ตาราง และตัวกรอง อ่าน PostgreSQL โดยตรงด้วย role ที่มีสิทธิ์ SELECT เท่านั้น ตรวจวันที่ 23 ตุลาคม 2569

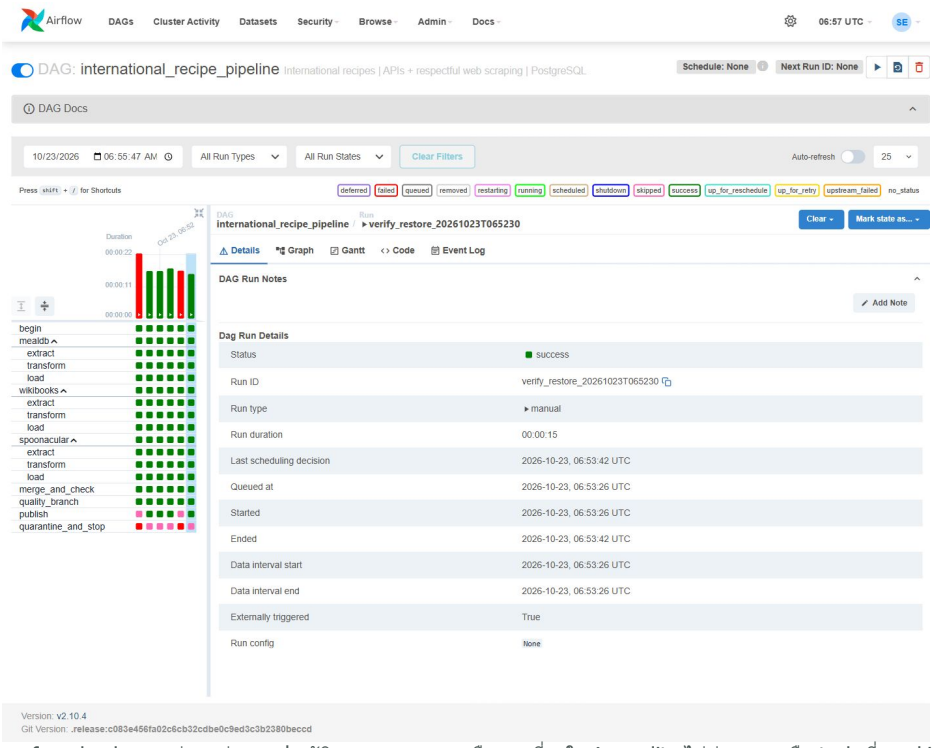
ข้อมูลแต่ละสูตรมีชื่อ วัตถุดิบ หมวด ประเทศและเวลาปรุงเมื่อมีข้อมูล พร้อม URL ที่มา ค่าที่ไม่ทราบเก็บเป็น NULL ใช้ requests + BeautifulSoup สำหรับ Wikibooks ตรวจ robots.txt และหน่วงคำขอ ไม่ใช้ Selenium และไม่เก็บข้อมูลส่วนบุคคล

การทำงานของ DAG และผลทดสอบ

TaskGroup สามแหล่งแยก extract → transform → load ทำงานขนาน รวมเป็น schema เดียวใน staging ก่อนตัดซ้ำและตรวจคุณภาพ แล้วเลือก publish หรือ quarantine_and_stop



Graph view ของ run คืนระบบที่สำเร็จ สีเขียวของ source task หมายถึงบันทึกผลการเรียกแล้ว แหล่งที่ไม่มี key ยังเป็น unavailable ใน source_status ไม่ใช่ดึงข้อมูลได้ครบสามแหล่ง



Grid view แสดง extract transform load ของแต่ละกลุ่มและประวัติรอบทดสอบ แดงคือรอบที่จงใจทำ quality ไม่ผ่าน ชมพูคือ task ที่ถูก skip ตาม branch

UPSERT ใช้ canonical_id จากชื่อและส่วนผสมที่ normalize รวมข้ามแหล่งเฉพาะข้อมูลตรงกัน เก็บ provenance สูตรชื่อเหมือนแต่ปริมาณต่างกันยังแยกกัน เมื่อ quality ผ่านจึงเปลี่ยน publication ใน transaction เดียว ข้อมูลเก่าที่ไม่อยู่ใน run ล่าสุดไม่ถูกนับปน

ผลตรวจ ปัญหา และการจัดลำดับงาน

หลักฐานทดสอบจริง

กรณีทดสอบ	ผลที่ตรวจได้
Unit และ PostgreSQL integration	ผ่าน 6 tests รวม parser, cross-source dedupe และ UPSERT
รัน DAG ซ้ำ	canonical 280 → 280 แถว ไม่เพิ่มซ้ำ
จำลอง TheMealDB ล่ม	DAG success และเผยแพร่ Wikibooks ได้ 180 สูตร
บังคับคุณภาพไม่ผ่าน	DAG failed ตามคาด pointer เดิมและ current 180 คงอยู่
คืนระบบและตรวจเว็บ	กลับเป็น 280 สูตร ตัวกรองและหน้า pipeline ผ่าน AppTest

ปัญหาที่พบและวิธีแก้

1. Airflow เขียน cache ไม่ได้
อาการ: extract task ขึ้น PermissionError ที่ /opt/airflow/data/http_cache
หาสาเหตุ: อ่าน task log พบว่า named volume เป็นของ root แต่ Airflow ใช้ UID 50000
แก้ไข: เพิ่ม volume-init ตั้ง owner ก่อนเริ่มระบบ แล้วทดสอบ DAG ใหม่จนเผยแพร่สำเร็จ

2. API response ขาดกลางทาง
อาการ: TheMealDB ขึ้น ChunkedEncodingError ทำให้รอบทดสอบแรกไม่มีข้อมูล usable
หาสาเหตุ: ตรวจ source_status.detail และ task log พบว่า network ล้มเหลวก่อน parse JSON
แก้ไข: เพิ่ม retry สูงสุด 3 attempts พร้อม backoff หากยังล่มบันทึก unavailable ให้แหล่งอื่นทำต่อ ทดสอบรอบปกติและรอบคืนระบบได้ 100 สูตรจาก API

ข้อจำกัดที่ยังเหลือ: ไม่มี Spoonacular key ระบบจึงทำงานจริงสองแหล่ง ต้องใส่ key ใน .env และดึงครบสามแหล่งก่อนยืนยันระดับ 3 การตัดซ้ำข้ามแหล่งผ่าน unit test แต่ชุดจริง 280 สูตรไม่พบ duplicate ตามกฎนี้

แผนจัดเวลาสามชั่วโมง

นาที 0–20 ตรวจโจทย์และแหล่งข้อมูล · 20–70 ทำ extract/transform · 70–110 ทำ PostgreSQL และ DAG · 110–145 ทำ dashboard · 145–180 ทดสอบ ถ่ายภาพ สรุป PDF และตรวจชุดส่ง โดยเป็นแผนจัดสรรเวลา ไม่ใช่บันทึกเวลาสอบจริง

ให้ความสำคัญกับระบบที่รันได้ระดับ 2 ก่อน แล้วเพิ่ม fault tolerance และ quality branch ตัดงานโภชนาการ ระบบสมาชิก fuzzy matching และ Dynamic Task Mapping ออก เพราะไม่จำเป็นต่อแกนโจทย์และเพิ่มภาระทดสอบ ใช้หน้าสถานะ pipeline เป็นงานโบนัส

หลักฐาน: evidence/verification.json, evidence/live_sources.json และ docs/TESTING.md ใน repo ผู้ส่งต้องตรวจ repo เป็น public และ commit ก่อนกำหนด พร้อมส่งลิงก์และ PDF ใน Classroom เอง